

PETROVISION MULTIMODAL

Avaliacao de representacoes DINOv2 em imagens petrográficas PPL e XPL

RELATORIO TECNICO

VERSAO 1.0.0

3 SET. 2026

Resumo executivo

O PetroVision Multimodal e uma prova de conceito reproduzível para curadoria e análise de imagens petrográficas de rochas carbonáticas. O estudo avalia se representacoes de um modelo visual auto-supervisionado preservam informacao util sobre quatro categorias quando o modo optico muda entre luz plano-polarizada (PPL) e luz polarizada cruzada (XPL). Foram usadas 336 imagens do DeepCarbonate, equilibradas por classe, modalidade e divisao oficial.

O DINOv2-small permaneceu congelado e forneceu um vetor CLS normalizado de 384 dimensoes por imagem. Classificadores lineares, K-Means, PCA e prototipos de classe foram usados como diagnosticos. Alem do teste oficial, uma validacao repetida aninhada mediu estabilidade sem reutilizar o teste na selecao de hiperparametros.

336	150	30
imagens auditadas	avaliacoes repetidas	testes automatizados

Resultado central

O treinamento combinado PPL+XPL apresentou o comportamento mais equilibrado, com macro-F1 medio de 0,675 em PPL e 0,650 em XPL. Os agrupamentos nao supervisionados foram fracos; portanto, o sinal acessivel ao probe linear nao equivale a uma separacao natural clara dos embeddings.

Pergunta de pesquisa

Representacoes DINOv2 congeladas conseguem separar as classes do recorte e manter utilidade quando a modalidade optica muda?

Autor: Rodrigo Rangel Goes e Silva

Repositorio: <https://github.com/RangelGS/PetroVision-Multimodal>

1. Dados e integridade

O recorte usa quatro categorias do DeepCarbonate: Cemented fracture, Micritic limestone, Oolite e Pore. Cada classe possui 42 imagens PPL e 42 XPL. As modalidades sao tratadas como dominios nao pareados porque o arquivo reorganizado nao oferece uma chave individual PPL-XPL confiavel.

Modalidade	Treino	Validacao	Teste	Total
PPL	120	28	20	168
XPL	120	28	20	168
Total	240	56	40	336

Garantias aplicadas

- Manifesto com origem, tamanho e SHA-256 de cada imagem.
- Bloqueio de identificadores ou conteudos identicos entre treino, validacao e teste.
- Triagem por pHash: dez candidatos revisados e mantidos como imagens distintas.
- Seis alertas de baixa luminosidade revisados; 336 imagens aceitas para modelagem.
- Imagens brutas fora do Git e uso sujeito a licenca declarada pelo DeepCarbonate.

2. Representacao e classificacao

Foi usado o checkpoint facebook/dinov2-small com revisao fixa. Seus pesos permaneceram congelados: o projeto aplicou o modelo pre-treinado, mas nao treinou o DINOv2. O token global CLS de 384 dimensoes foi normalizado por L2. Regressao logistica foi treinada em seis cenarios: intra-dominio, transferencia entre dominios e treino combinado com avaliacao separada em PPL e XPL.

3. Protocolo de avaliacao

- Experimento principal: C escolhido somente na validacao; ajuste em treino+validacao; teste consultado apenas para avaliacao final.
- Estabilidade: cinco dobras externas e cinco repeticoes, com tres dobras internas para escolher C.
- Total de 25 medicoes por cenario e 150 medicoes no conjunto de desenvolvimento.
- Teste oficial excluido da validacao repetida por construcao.
- Desvio-padrao descritivo, pois as dobras repetidas se sobrepoem.

Diagnosticos complementares

K-Means com quatro grupos foi comparado a classe e modalidade usando ARI e NMI. PCA bidimensional apoiou a visualizacao. O alinhamento entre PPL e XPL foi medido por similaridade cosseno entre prototipos medios de classe, sem inventar pares individuais.

4. Resultados no teste oficial

O teste oficial contem 20 imagens por modalidade, cinco por classe. Por isso, uma diferenca pequena pode representar apenas uma ou duas imagens e deve ser interpretada junto com a analise repetida.

Treino	Avaliacao	Acuracia balanceada	Macro-F1
PPL	PPL	0,550	0,488
PPL	XPL	0,600	0,581
PPL+XPL	PPL	0,650	0,635
PPL+XPL	XPL	0,550	0,557
XPL	PPL	0,550	0,534
XPL	XPL	0,550	0,473

O melhor macro-F1 ocorreu no treino combinado avaliado em PPL (0,635). Cemented fracture foi reconhecida de forma consistente, enquanto Micritic limestone foi uma fonte frequente de confusao. Os seis resultados permanecem acima do acaso de 0,25, mas o tamanho do teste limita comparacoes finas.




Figura 1. Matrizes de confusao dos seis cenarios no teste oficial fixo.

5. Estabilidade no conjunto de desenvolvimento

A tabela resume 25 medicoes por cenario. A linha vermelha da figura marca o acaso de 0,25 para quatro classes equilibradas.

Treino	Avaliacao	Macro-F1 medio ± DP	Minimo-maximo
PPL	PPL	0,673 ± 0,063	0,524-0,765
PPL	XPL	0,587 ± 0,104	0,343-0,850
PPL+XPL	PPL	0,675 ± 0,073	0,531-0,829
PPL+XPL	XPL	0,650 ± 0,088	0,413-0,830
XPL	PPL	0,509 ± 0,078	0,325-0,618
XPL	XPL	0,691 ± 0,091	0,527-0,864

O treino combinado foi o mais equilibrado: manteve PPL proximo ao treino PPL e melhorou XPL em relacao ao treino apenas PPL. A transferencia XPL para PPL teve a menor media. PPL para XPL apresentou o maior desvio-padrao, indicando sensibilidade a composicao das dobras.




Figura 2. Distribuicao de macro-F1 na validacao repetida aninhada.

6. Diagnosticos do espaco de embeddings

O K-Means obteve ARI de classe 0,129, NMI de classe 0,186 e silhouette 0,059. Para modalidade, ARI e NMI foram 0,004 e 0,011. A PCA explica 17,1% da variancia em duas dimensoes e exibe sobreposicao. Esses valores nao sustentam a existencia de grupos naturais fortemente alinhados as classes ou ao modo optico.




Figura 3. PCA por classe/modalidade e similaridade entre prototipos PPL-XPL.

A similaridade media entre prototipos da mesma classe foi 0,953, contra 0,874 entre classes diferentes (gap 0,079). Existe alinhamento, mas as similaridades elevadas fora da diagonal tambem mostram pequena margem entre categorias.

7. Limitacoes

- Quatro classes, uma fonte de dados e nenhum teste externo de laboratorio.
- Cinco imagens de teste por classe e modalidade.
- Rotulos herdados, sem revalidacao por especialista neste projeto.
- PPL e XPL nao pareados; DINOv2 congelado; repeticoes sobrepostas.

8. Conclusao

As representacoes DINOv2 contem sinal util para classificacao linear, e o treinamento combinado e a alternativa mais equilibrada no recorte. O agrupamento fraco e a variacao impedem alegacoes de separacao universal. O resultado principal e um fluxo auditavel que vai da curadoria a analise de estabilidade, nao um diagnostico geologico.

Referencias

1. Oquab, M. et al. DINOv2: Learning Robust Visual Features without Supervision. arXiv:2304.07193, 2023. <https://arxiv.org/abs/2304.07193>
2. Li, K. et al. A dataset and benchmark of carbonate thin-section images for deep learning. Scientific Data 13, 340, 2026. <https://doi.org/10.1038/s41597-026-06633-5>
3. DeepCarbonate. Zenodo. <https://doi.org/10.5281/zenodo.18061204>